

DATATHON 2026: THE GRIDBREAKER

Giải pháp Dự báo Doanh thu & Tối ưu Vận hành

Lê Đăng Thái An, Dương Quốc Hữu, Đinh Đồng Tiến

FPT University

anle26022006@gmail.com, tienddse200934@fpt.edu.vn, huuabc123456789@gmail.com

Abstract

Báo cáo này đề xuất một giải pháp toàn diện cho bài toán dự báo doanh thu và tối ưu hóa vận hành của một doanh nghiệp thương mại điện tử thời trang. Thông qua việc phân tích chuyên sâu tập dữ liệu lịch sử (2012-2022), chúng tôi đã bóc tách thành công tính mùa vụ, định lượng hiệu ứng "ăn mòn" của các chiến dịch khuyến mãi và chẩn đoán rủi ro dòng tiền từ hàng tồn kho. Những phát hiện này là kim chỉ nam để thiết kế các đặc trưng (features) cốt lõi, phục vụ huấn luyện mô hình học máy (Machine Learning) kết hợp đa tầng, nhằm dự báo Doanh thu (Revenue) và Giá vốn hàng bán (COGS) với độ chính xác và tính ổn định cao. Mã nguồn toàn bộ hệ thống được công khai tại: https://github.com/DongTienDinh/Cheemsity_Datathon_2026.


1 Introduction

Trong thị trường E-commerce thời trang, biên độ dao động nhu cầu lớn và tính mùa vụ phức tạp đặt ra bài toán khó cho việc quản trị tồn kho và tối ưu hóa chiến lược giá. Báo cáo này giải quyết bài toán thông qua hai trọng tâm: (1) Khai phá dữ liệu (EDA) nhằm chẩn đoán sâu các động lực cốt lõi chi phối doanh thu và (2) Thiết kế một *Hybrid Ensemble Pipeline* giúp dự báo chuẩn xác doanh thu tương lai, ngăn chặn tình trạng rò rỉ dữ liệu (data leakage) và đảm bảo ràng buộc logic kinh tế.

2 Trực quan hoá và Phân tích Dữ liệu (EDA)

Phân tích được thiết kế bám sát theo 4 cấp độ: Mô tả (Descriptive), Chẩn đoán (Diagnostic), Dự báo (Predictive) và Đề xuất hành động (Prescriptive).


2.1 Tính mùa vụ và Hiệu ứng Khuyến mãi (Seasonality & Promo Cannibalization)



Hình 1: Phân phối Doanh thu theo Tháng và Tác động của các sự kiện Khuyến mãi.

- **Mô tả & Chẩn đoán:** Dữ liệu cho thấy doanh thu tập trung cực lớn vào Quý 4. Các đỉnh doanh thu luôn trùng khớp với ngày diễn ra sự kiện khuyến mãi lớn (Hình 1). Tuy nhiên, ngay sau khi kết thúc chuỗi sự kiện, doanh thu lập tức suy giảm sâu dưới mức trung bình. Đây là hiện tượng *hiệu ứng ăn mòn* (Cannibalization)—khách hàng đã dần quen với các đợt sale và có tâm lý trì hoãn việc mua sắm ở mức giá nguyên bản (full-price).
- **Dự báo & Đề xuất:** Việc duy trì tần suất giảm giá trực tiếp quá dày đặc sẽ làm mỏng biên lợi nhuận gộp mà không tạo ra lượng cầu thực tế mới. Đề xuất chuyển dịch trọng tâm sang chiến lược giá Buy More Save More (ví dụ: kích thích tăng giá trị đơn hàng tối thiểu *min_order_value* để được nhận ưu đãi). Điều này giúp gia tăng *Average Order Value* (AOV), bảo vệ hệ thống cung ứng khỏi những cú sốc đứt gãy sau các ngày lễ lớn.


2.2 Ma trận Sức khỏe Tồn kho (Inventory Health Matrix)



Hình 2: Ma trận Sức khỏe Tồn kho dựa trên Tỷ lệ bán ra và Số ngày đáp ứng.

- **Mô tả & Chẩn đoán:** Thông qua ma trận 2x2 (Hình 2), hệ thống bóc tách hai rủi ro. Nhóm *Động vốn* (lưu kho cao, tỷ lệ bán ra < 20%) là biểu hiện của việc *over-forecasting* trong quá khứ. Nhóm *Mất doanh thu* (tỷ lệ bán > 60%, lưu kho thấp) liên tục kích hoạt trạng thái đứt hàng (*stockout_flag*), làm giảm tỷ lệ chuyển đổi.
- **Dự báo & Đề xuất:** Đề xuất kích hoạt các đợt thanh lý (Markdown xả kho) giảm sâu 30-40% cho nhóm động vốn để tối ưu dòng tiền. Với nhóm rủi ro đứt hàng, cần tự động hóa việc tính toán lại điểm tái đặt hàng (Reorder Point) và mở rộng lượng hàng dự trữ an toàn (Safety Stock) lên khoảng 15% trong các kỳ cao điểm mùa vụ.

2.3 Chỉ số dẫn xuất (Leading Indicators): Web Traffic và Doanh thu



Hình 3: Mối tương quan tuyến tính giữa Lưu lượng truy cập (Sessions) và Doanh thu.

- **Mô tả & Chẩn đoán:** Lượng truy cập (sessions) có tương quan dương mạnh mẽ với doanh thu (Hình 3). Tuy nhiên, mức độ phân tán dữ liệu ở dải traffic cao cho thấy tỷ lệ chuyển đổi không ổn định, nguyên nhân chính từ sự gia tăng của tỷ lệ thoát (bounce_rate) ở các luồng traffic đến từ các chiến dịch Ads kém chất lượng.
- **Dự báo & Đề xuất:** Biến sessions phải được ưu tiên tích hợp làm đặc trưng gốc cho hệ thống học máy. Về chiến lược, cần rà soát lại và cắt giảm khoảng 20% ngân sách tiếp thị ở các nguồn mang bounce_rate cao, dồn lực tối ưu hóa lại giao diện người dùng (UI/UX) cho website.

3 Mô hình Dự báo Doanh thu & Giá vốn (Forecasting Pipeline)

Được thúc đẩy bởi những phát hiện từ EDA, chúng tôi xây dựng một **Optimized Ensemble Pipeline** nhằm giải quyết triệt để tính dị biệt của dữ liệu và hiện tượng Data Leakage. Pipeline áp dụng chiến lược học máy 2 tầng (Stacking). Toàn bộ quy trình và mã nguồn chi tiết xem tại https://github.com/DongTienDinh/Cheemsity_Datathon_2026.

3.1 Kiến trúc Hybrid Ensemble & Tối ưu Hàm Mục tiêu

- **Tách bóc Xu hướng bằng Prophet:** Chuỗi thời gian chứa rất nhiều yếu tố phi tuyến. Ở tầng tiền xử lý, trên từng nếp gấp dữ liệu (fold), chúng tôi triển khai mô hình Prophet để phân rã dữ liệu thành đường *xu hướng toàn cục (Global Trend)* và *yếu tố mùa vụ (Seasonality)*. Kết quả $residual = \log(Revenue) - prophet_trend$ trở thành mục tiêu dự báo chính cho các mô hình Machine Learning ở tầng sau. Điều này giúp các mô hình phức tạp dễ dàng hội tụ và hội tụ nhanh hơn.
- **Mô hình Base (Layer 1) với Huber Loss:** Dữ liệu tồn tại rất nhiều điểm đột biến (spikes) trong các ngày sale lớn. Để mô hình không bị "mất phương hướng" bởi các điểm này, chúng tôi đào tạo ba mô hình Tree-based tiên tiến: **XGBoost**, **LightGBM**, và **CatBoost**. Điểm đột phá là việc ép buộc tất cả các mô hình này sử dụng **Huber Loss** (hoặc pseudohubererror). Huber Loss có khả năng kết hợp sức mạnh của MSE (ổn định) và MAE (kháng nhiễu), giúp dự báo cực kỳ robust.
- **Mô hình Meta (Layer 2 - Stacking):** Kết quả OOF (Out-of-Fold) sinh ra từ 3 Base Models được ghép lại làm đầu vào cho mô hình **HuberRegressor** ở Layer 2. HuberRegressor đóng vai trò như một bộ lọc (blender), tối ưu hóa trọng số của từng mô hình cơ sở bằng thuật toán GridSearchCV nhằm tạo ra giá trị dự đoán $\log(Revenue)$ cuối cùng ít sai số nhất.
- **Xử lý Ràng buộc Giá vốn (COGS):** Dự báo độc lập giá trị tuyệt đối của COGS rất dễ dẫn đến lỗi toán học phi logic ($COGS > Revenue$). Do đó, chúng tôi kiến trúc một nhánh dự báo riêng biệt cho tỷ lệ $COGS_Ratio = COGS / Revenue$. Tỷ lệ này biến thiên vô cùng ổn định quanh mốc $[0, 1]$. Cuối cùng, $COGS$ được nội suy bằng $Revenue_Prediction \times COGS_Ratio_Prediction$.

3.2 Kỹ thuật Kéo dẫn Đặc trưng (Feature Engineering) & Kiểm soát Leakage

Một ma trận tổng hợp gồm **89 features** được chế tác thủ công để truyền thụ kiến thức cho hệ thống:

- **Lịch & Các sự kiện (Calendar & Events):** Khoảng cách tính bằng ngày đến Tết Âm lịch, phân hạng các mùa Sale theo biểu đồ EDA, và chỉ số tiệm cận đỉnh mùa vụ (*peak_proximity*).
- **Traffic & Inventory:** Lồng ghép các chỉ số Vận hành như Sessions, Bounce Rate, tỷ lệ Stockout, và Overstock hàng tháng (Leading indicators).
- **Động lượng Chuỗi thời gian (Lag/Rolling/EWM):** Khai thác tối đa trí nhớ của dữ liệu quá khứ bằng cách tính toán doanh thu trễ (lag 7, 14, 28, 365 days), đường trung bình trượt (rolling mean/std), và biến động theo hàm mũ (EWM).
- **Loại bỏ Rò rỉ Dữ liệu (No Leakage):** Hệ thống sử dụng **4-fold Walk-Forward Cross-Validation** (Mở rộng dần cửa sổ huấn luyện từ 2019-2022). Đặc biệt trong pha Test Prediction, tính toán được cấu trúc theo **Quy trình Suy luận Lặp (Iterative Test Prediction)**: dự báo ngày T được xuất ra, đẩy ngay lập tức vào bộ nhớ lịch sử, rồi mới dùng chính lịch sử đó để nội suy các đặc trưng Lag/Rolling cho ngày $T + 1$.

3.3 Giải thích Mô hình (Model Interpretability)

Việc kiểm tra biểu đồ *Feature Importance (SHAP/Gain)* trên kiến trúc LightGBM cho thấy tính năng sessions (lượng truy cập Web) và rev_rmean7 (Doanh thu trung bình 7 ngày gần nhất) đóng góp thông tin (Gain) mạnh mẽ nhất. Điều này hoàn toàn củng cố cho phát hiện cốt lõi từ EDA: trong bức tranh E-commerce, traffic là cánh cửa đón dòng tiền đầu tiên, và quán tính tăng trưởng ngắn hạn là chìa khóa định hình đỉnh/đáy của chu kỳ bán hàng.